

基于 Waring 理论与 Taylor 方向导数的 单项高阶偏导精确算法

论文汇报

June 2, 2026

June 2, 2026

汇报提纲

- 1 问题与对偶
- 2 等价性与显式构造
- 3 实现与工程
- 4 数值算例
- 5 结论与下阶段

研究背景与动机

在 PINN、神经网络变分蒙特卡洛、随机最优控制等问题中，需要反复计算神经网络 u 的某一固定的高阶混合偏导

$$\partial^\alpha u(\mathbf{x}) = \partial_{i_1} \partial_{i_2} \cdots \partial_{i_p} u(\mathbf{x}), \quad |\alpha| = p \geq 2.$$

典型场景包括 Cahn-Hilliard 的 $\partial_x^2 \partial_y^2$ 、KdV 的 ∂_x^3 、双调和及高阶 polyharmonic、梁与薄板方程的 ∂_x^4 等。

现有路径的瓶颈。最直接的方案是嵌套调用 p 次 `torch.autograd.grad` (开启 `create_graph=True`)。自动求导图深度为 $\Theta(pL)$ ，激活内存为 $\Theta((p+1)L)$ ，并随 p 平方级地累积图重建与算子派发开销。在 $p=6$ 的中等规模网络上，单次 $\partial^\alpha u$ 调用已进入数十毫秒量级，是 PINN 训练的主要瓶颈。

本工作目标。对每一个给定的多重指标

α ，提供一种确定性、精度达机器精度、并可端到端反传的高阶偏导计算后端，在含重复指标的中高阶情形下显著快于嵌套自动求导。

活动子空间与符号约定

活动指标与指数. 设 α 中实际出现的坐标下标为 $i_0, \dots, i_n$ (共 $n+1$ 个), 对应重数 $1 \leq a_0 \leq a_1 \leq \dots \leq a_n$. 约定

$$|\alpha| = \sum_{j=0}^n a_j = p, \quad \alpha! = \prod_{j=0}^n a_j!.$$

下文一律将方向取值限制在 $(n+1)$ 维空间 $\mathbb{R}^{n+1} = \{(v_0, \dots, v_n)\}$, 其中第 j 个分量 v_j 对应坐标方向 e_{i_j} .

两个不同角色的对象. 方向 $v \in \mathbb{R}^{n+1}$ 是求方向 Taylor 系数时代入的具体向量; 对偶变量 $z = (z_0, \dots, z_n)$ 是 $\mathbb{R}[z]_p$ 中作为不定元的符号变量. 线性形式 $v \cdot z \in \mathbb{R}[z]_1$ 由方向 v

的分量唯一决定: $v \cdot z = \sum_{j=0}^n v_j z_j$.

方向 Taylor 系数. 对方向 $v \in \mathbb{R}^{n+1}$,

$$T_p(x; v) := \frac{1}{p!} \frac{d^p}{d\tau^p} u(x + \tau v) \Big|_{\tau=0} = \frac{1}{p!} D^p u(x)[v, \dots, v].$$

两个最优化问题

问题 (P) : 方向导数的最小个数

寻找最小的 $R \in \mathbb{N}$ 与 $c_r \in \mathbb{R}$ 、 $v_r \in \mathbb{R}^{n+1}$, 使得

$$\partial^\alpha u(x) = \sum_{r=1}^R c_r T_p(x; v_r) \quad \text{对任意光滑 } u \text{ 都成立.} \quad (*)$$

问题 (Q) : 单项 z^α 的 Waring 秩

寻找最小的 $R \in \mathbb{N}$ 与 $c_r \in \mathbb{R}$ 、 $v_r \in \mathbb{R}^{n+1}$, 使得作为 $\mathbb{R}[z]_p$ 中的多项式恒等式 ,

$$p! z^\alpha = \sum_{r=1}^R c_r (v_r \cdot z)^p \quad (\diamond)$$

最小的 R 称为单项 z^α 在 $\mathbb{R}$ 上的实 Waring 秩 , 记 $R_{\mathbb{R}}(z^\alpha)$ 。

Carlini-Catalisano-Geramita 的闭式秩公式

从 $\mathbb{R}$ 扩展到 $\mathbb{C}$. 问题 (P)、(Q) 默认在 $\mathbb{R}$ 上提出, 但若允许 $c_r \in \mathbb{C}$ 、 $v_r \in \mathbb{C}^{n+1}$ (即把 $\mathbb{R}$ 替换为 $\mathbb{C}$), 最优值会变小, 记为 $R_{\mathbb{C}}(z^\alpha)$. 实方向只是复方向的一个特例, 因此 $R_{\mathbb{C}}(z^\alpha) \leq R_{\mathbb{R}}(z^\alpha)$. 下面的定理给出 R 的闭式.

Theorem (Carlini-Catalisano-Geramita, 2012)

对 $z^\alpha = z_0^{a_0} z_1^{a_1} \cdots z_n^{a_n}$, $1 \leq a_0 \leq \cdots \leq a_n$, 有

$$R(z^\alpha) = \prod_{j=1}^n (a_j + 1) = \frac{\prod_{j=0}^n (a_j + 1)}{a_0 + 1}.$$

上界由单位根构造给出 (见后页); 下界基于 apolar 理想 $(\partial_0^{a_0+1}, \dots, \partial_n^{a_n+1})$ 为 complete intersection 这一事实, 由 Hilbert 函数推得.

桥定理：(P) 与 (Q) 严格等价

Theorem (apolarity 桥定理)

对任意 $R \in \mathbb{N}$ 、 $c_r \in \mathbb{R}$ 、 $v_r \in \mathbb{R}^{n+1}$ ，下述两命题相互充要：

- (1) 等式 $\partial^\alpha u(x) = \sum_{r=1}^R c_r T_p(x; v_r)$ 对任意 $u \in C_x^p$ 成立；
- (2) 多项式 $p! z^\alpha$ 与 $\sum_{r=1}^R c_r (v_r \cdot z)^p$ 在 $\mathbb{R}[z]_p$ 中相等。

推论：(P) 与 (Q) 同解

方向导数的最小个数 $R_{\mathbb{R}}^*(\alpha)$ 等于 $R_{\mathbb{R}}(z^\alpha)$ ；且 (c_r, v_r) 是 (P) 的最优解当且仅当其同时是 (Q) 的最优解。

桥定理把 (P) 的“对任意光滑 u 都成立”等价转化为 $\mathbb{R}[z]_p$ 中的一个有限维多项式恒等。对上的版本，证明完全平行（用 $[z]_p$ 替换 $\mathbb{R}[z]_p$ ），故复方向也由对应的复 Waring 分解给出。

桥定理的证明

把 (P) 与 (Q) 各自展开后，两者都化简为同一组有限维线性方程

$$\sum_{r=1}^R c_r v_r^\beta = \alpha! \delta_{\alpha\beta}, \quad \forall |\beta| = p. \quad (*)$$

(P) $\Leftrightarrow$ (*). 代入 $T_p(x; v_r) = \sum_{|\beta|=p} \partial^\beta u(x) v_r^\beta / \beta!$ 并交换求和：

$$(P) \iff \sum_{|\beta|=p} \left[\sum_{r=1}^R c_r v_r^\beta \right] \frac{\partial^\beta u(x)}{\beta!} = \partial^\alpha u(x), \quad \forall u,$$

令 u 跑遍 p 次单项以单项基测试上式，即得 (*)。

(Q) $\Leftrightarrow$ (*). 代入 $(v_r \cdot z)^p = \sum_{|\beta|=p} \binom{p}{\beta} v_r^\beta z^\beta$ 并比较 z^β 系数：

$$(Q) \iff \binom{p}{\beta} \sum_{r=1}^R c_r v_r^\beta = p! \delta_{\alpha\beta} \iff (*),$$

最后一步利用 $p! / \binom{p}{\beta} = \beta!$ 与 $\delta_{\alpha\beta} \cdot \beta! = \alpha! \delta_{\alpha\beta}$ 。

□

达到下界的单位根构造

由桥定理，求解 (P) 等价于在 $[z]_p$ 中给出长度为 $R_{(z^\alpha)}$ 的 Waring 分解。CCG 给出如下闭式构造：

以最小指数变量 z_0 作为基方向。记 $m_j := a_j + 1$ ，并记 m_j 次单位根集合 $U_{m_j} := \{\zeta \in \mathbb{C} : \zeta^{m_j} = 1\}$ 。对每一个 $\zeta = (\zeta_1, \dots, \zeta_n) \in U_{m_1} \times \dots \times U_{m_n}$ ，令

$$v_\zeta = e_{i_0} + \sum_{j=1}^n \zeta_j e_{i_j}, \quad c_\zeta = \frac{\alpha!}{\prod_{j=1}^n m_j} \prod_{j=1}^n \zeta_j.$$

则

$$\partial^\alpha u(x) = \sum_{\zeta \in U_{m_1} \times \dots \times U_{m_n}} c_\zeta T_p(x; v_\zeta),$$

方向数恰为 $\prod_{j=1}^n m_j = \prod_{j=1}^n (a_j + 1) = R_{(z^\alpha)}$ 。

为何使用单位根。对每个 j 单独求和后，单位根求和恒等式 $\sum_{\zeta \in U_m} \zeta^k = m \cdot 1_{\{m \mid k\}}$ 起到 δ

滤波的作用：在所有 z^β 系数中仅 $\beta = \alpha$ 一项保留，其余系数自动相消。

重复指标举例与方向数对比

记 $U_m = \{\zeta \in: \zeta^m = 1\}$ 。

$u_{12} (\alpha = (1, 1), R = 2)$:

$$u_{12}(x) = \frac{1}{2} \sum_{\zeta \in U_2} \zeta T_p(x; e_1 + \zeta e_2).$$

展开即 $\frac{1}{2} T_p(x; e_1 + e_2) - \frac{1}{2} T_p(x; e_1 - e_2)$ 。

$u_{1122} (\alpha = (2, 2), R=3, R_{\mathbb{R}} = 4)$:

$$u_{1122}(x) = \frac{4}{3} \sum_{\zeta \in U_3} \zeta T_p(x; e_1 + \zeta e_2).$$

其中 $U_3 = \{1, \omega, \omega^2\}$, $\omega = e^{2\pi i/3}$ 。

$u_{112233} (\alpha = (2, 2, 2), R=9, R_{\mathbb{R}} \leq 13)$:

$$u_{112233}(x) = \frac{8}{9} \sum_{\substack{\zeta_1 \in U_3 \\ \zeta_2 \in U_3}} \zeta_1 \zeta_2 T_p(x; e_1 + \zeta_1 e_2 + \zeta_2 e_3).$$

共 9 对 (ζ_1, ζ_2) 。

pattern	R	$R_{\mathbb{R}}$	polariz.
(p)	1	1	$\leq 2^{p-1}$
(2, 1)	3	3	3
(1, 1, 1)	4	4	4
(3, 1)	4	4	—
(2, 2)	3	4	4
(2, 1, 1)	6	6	6
(1, 1, 1, 1)	8	8	8
(4, 2)	5	≤ 7	7
(2, 2, 2)	9	≤ 13	13
(1 ⁶)	32	32	32

红色行：复方向严格少于实方向方案，均出现于 $a_0 \geq 2$ 、支撑数 ≥ 2 时。 $a_0 = 1$ 时由 CKOV (2017) 有 $R_{\mathbb{R}} = R$ ；square-free 在 $\mathbb{R}$ 与 $\mathbb{C}$ 上均达到 2^{p-1} 。

方向 $T_p(x; v)$ 的高效评估：Taylor 前向 AD

对每个方向 v_r 各计算一次 $T_p(x; v_r)$ 。将每层中间张量 y 扩展为长度 $p + 1$ 的元组 $(y_0, y_1, \dots, y_p)$ ，其中 $y_k = \frac{1}{k!} d^k y / d\tau^k|_{\tau=0}$ 。各算子的 jet 规则：

线性层 $y = Wx + b$ ： $y_0 = Wx_0 + b$ ， $y_k = Wx_k$ ($k \geq 1$)。实现上将 $p + 1$ 个阶沿 batch 轴拼接，整层只执行一次 GEMM。

sinh 激活（取辅助 jet $z = \cosh(x)$ ）：对 $k \geq 1$

$$y_k = \frac{1}{k} \sum_{j=0}^{k-1} (k-j) z_j x_{k-j}, \quad z_k = \frac{1}{k} \sum_{j=0}^{k-1} (k-j) y_j x_{k-j}.$$

$\tanh, \sigma, \sin$ 的耦合递推具有相同形式。 $\sinh, \cosh$ 在 $\mathbb{R}$ 上是整函数，可直接用于复方向。

每个激活 jet 实现为 `torch.autograd.Function`，并提供闭式 VJP

$g_x^{(m)} = \sum_{j=0}^{p-m} \overline{q_j} g_y^{(m+j)}$ ，反向阶段无需对 jet 内部递推单独建图。

加速来源分析

记单次普通前向开销 $C_{\text{fwd}} = O(LBH^2)$ (L 层、batch B、宽度 H)，
自动求导每个算子的派发常数为 κ 。 $O(\cdot)$ 表示渐近运行时 (略去常数因子)。

	嵌套自动求导	Waring + Taylor jet
渐近时间	$O(p^2 C_{\text{fwd}} + pL\kappa)$	$O(R \cdot (p C_{\text{fwd}} + LBHp^2))$
自动求导图	深度 $O(pL)$ ；每次 grad 重放	不依赖图链
每方向常数	每阶单独构图与派发	一次 GEMM 同时处理 $p+1$ 阶
与指数模式关系	与 α 形式无关	通过 $R(\alpha)$ 利用模式信息

Waring + Taylor jet 时间的来源 (每方向)。Linear 层把 $p+1$ 阶沿 batch 维拼成一次 GEMM，全网共 $O(p C_{\text{fwd}})$ ；激活层耦合递推 $y_k = \frac{1}{k} \sum_{j < k} (k-j) z_j x_{k-j}$ 中 k 跑到 p ，全网共 $O(LBHp^2)$ 。再乘 R 个方向。

加速来源 (四个相互独立的因素)。(i) 前向模式更适合标量输出 + 少量方向的高阶导数；(ii) 消除嵌套求导的 $O(p^2)$ 图重放与每算子派发常数 κ ；(iii) 合并矩阵乘，把 $p+1$ 阶沿 batch 维拼接到一次 GEMM；(iv) 方向数代数最优，含重复指标时 $R \leq R_{\mathbb{R}} \leq 2^{p-1}$ 严格更小。

方法定位及与已有工作的关系

方法	定位	与本方法的关系
嵌套自动求导	任意 α , 精确 , 慢	本方法的精度对照与基线
real polariza- tion	任意 α , 精确 , 实方向	本方法的兜底回退 ; $a_0 = 1$ 与 square-free 时与之相当
Taylor 前向 AD (JAX/Julia)	任意单方向 T_p , 精确	作为本方法的底层求值原语
Forward Lapla- cian	仅针对 Δ 等迹型算子	适用范围正交 ; 本方法只处理单一 α
STDE (NeurIPS 2024)	任意算子 ; 随机 + 分区 jet	互补 : 本方法对单 给出确定性精确解 , STDE 提供任意算子的无偏估计

本方法不涉及. Δ^k 、迹收缩 $\text{tr}(\sigma\sigma^\top\partial^2)$ 以及一般可 contract 的算子求和 ; 这一类问题更适合 trace-collapsing 类方法。

适用场景. PDE 残差中存在单一占主导地位、含重复指标的中高阶单项 (如 $\partial_x^4\partial_y^2$ 、 $\partial_x^2\partial_y^2$) 的 PINN 训练。

PINN 实验：四维六阶 Cahn-Hilliard 类方程

方程与精确解. 在 $\Omega = (-1, 1)^4$ 上求解

$$\partial_{x_1}^4 \partial_{x_2}^2 u(x) = f(x), \quad u_{\text{exact}}(x) = \sinh(x_1) \cos(x_2) e^{-(x_3^2 + x_4^2)/4}.$$

由 $\sinh^{(4)} = \sinh$ 、 $\cos^{(2)} = -\cos$ ，源项闭式为 $f = -u_{\text{exact}}$ 。活动指数模式 $(4, 2)$ ，故 $R=5$ 、 $R_{\mathbb{R}} \leq 7$ （实极化方向数）。

网络与损失. 4 层 Linear-sinh 多层感知机，宽度 64，参数取值于 $\mathbb{C}$ （`torch.complex128`）。以 $\Re u$ 为物理解，损失项为

$$\|\Re \partial^{(4,2)} u - f\|_{\Omega}^2 + 100 \|\Re u - u_{\text{exact}}\|_{\partial\Omega}^2 + 10^{-6} \sum_W \|\Im W\|^2.$$

对照设置. Tesla T4，每个 backend 给定相同的 wall-clock 预算 60 秒，内点采样 128、边界采样 64，Adam（学习率 10^{-3} ）。三个 backend 在同一损失、同一初始化、同一采样下做对照。

PINN 实验结果

backend	steps	ms/step	显存峰值 (MB)	最终 L_{int}	相对 L^2 误差
waring complex jet	4248	14.1	40	1.74×10^{-3}	8.50×10^{-3}
polarization jet	4192	14.3	49	6.32×10^{-3}	4.43×10^{-2}
嵌套自动求导	211	285.6	103	2.82×10^{-1}	2.49×10^{-1}

观察.

- 两条 jet 路径单步耗时为嵌套自动求导的约 1/20，显存约 1/2.5；60 秒预算下嵌套自动求导仅完成 211 步， L^2 误差停在 0.25 量级；
- 复 Waring 路径达到 $R=5$ ，比实极化方向 7 严格少 2 个方向，相同时间内的最终 L^2 误差领先约 5 倍（ 8.5×10^{-3} 对 4.4×10^{-2} ）；
- $\sinh$ 在上为整函数，复方向 jet 与复参数模型可直接耦合，无需逐步类型转换。

结论与下阶段工作

结论.

- 给定 α 的方向调度问题 (P) 与单项 z^α 的 Waring 分解问题 (Q) 严格等价；
- 基于 Carlini–Catalisano–Geramita 的闭式秩公式与单位根构造，方向数达到复数域上的信息论下界 $\prod_{j \geq 1} (a_j + 1)$ ；
- 与 Taylor 前向 jet 配合后，整套方法在 fp64 下达到机器精度，且支持参数反传；
- 在含重复指标的中高阶情形下，相比嵌套自动求导有显著加速。

下阶段工作.

- 扩展至更高阶、更高维以及多分量耦合的复杂 PDE 算例（如 KdV 高阶变体、薄板与梁方程、Schrödinger 类方程），系统检验复参数 + sinh PINN 在不同方程类型上的稳定性；
- 在统一架构下与 STDE 进行精度-运行时间的系统比较，给出确定性精确路径相对于随机无偏估计在不同 α 上的优劣边界。

谢谢聆听

欢迎讨论与建议